## Haskell Beats C Using Generalized Stream Fusion

Geoffrey Mainland

Microsoft Research Ltd

Chalmers, December 2012

Joint work with Roman Leshchinskiy, Simon Peyton Jones, and Simon Marlow.

## The challenge...

- ► Write high-level, *high-performance*, sequence-processing code. Think numerical code and vectors.
- In particular, allow compositional code without sacrificing performance.
- ► Should be able to take advantage of special-case operations, e.g., bulk memory copies and SIMD instructions.

## The plan

- Overview of streams and stream fusion (old news).
- Generalized stream fusion. Simultaneously maintain several representations, and pick the best one depending on operations performed.
- Craft a representation tailored for computing with SSE instructions.
- ▶ Produce efficient numerical code from Haskell, i.e., how to make Haskell beat C!

**Fusion** 

 $\mathsf{map}\; \mathsf{f} \circ \mathsf{map}\; \mathsf{g}$ 

### **Fusion**

$$\mathsf{map}\; \mathsf{f} \circ \mathsf{map}\; \mathsf{g} \equiv \mathsf{map}\; (\mathsf{f} \circ \mathsf{g})$$

#### Stream fusion

- Recursive functions are hard for the compiler to optimize.
- ► So turn recursive functions into non-recursive functions via a change in representation.
- ▶ Instead of working with lists or vectors, work with Streams.

### Stream fusion

#### data Stream a where

 $\mathsf{Stream} :: (\mathsf{s} \to \mathsf{Step} \ \mathsf{s} \ \mathsf{a}) \to \mathsf{s} \to \mathsf{Int} \to \mathsf{Stream} \ \mathsf{a}$ 

data Step s a = Yield a s

Skip s Done

### map, now with Streams

 $\begin{aligned} \mathsf{map} &:: (\mathsf{a} \to \mathsf{b}) \to \mathsf{Vector} \; \mathsf{a} \to \mathsf{Vector} \; \mathsf{b} \\ \mathsf{map} \; \mathsf{f} &= \mathsf{unstream} \circ \mathsf{map_s} \; \mathsf{f} \circ \mathsf{stream} \end{aligned}$ 

# map, now with Streams

```
\mathsf{map} :: (\mathsf{a} \to \mathsf{b}) \to \mathsf{Vector} \ \mathsf{a} \to \mathsf{Vector} \ \mathsf{b} \mathsf{map} \ \mathsf{f} = \mathsf{unstream} \circ \mathsf{map}_\mathsf{s} \ \mathsf{f} \circ \mathsf{stream}
```

```
\begin{aligned} \mathsf{map}_s &:: (\mathsf{a} \to \mathsf{b}) \to \mathsf{Stream} \; \mathsf{a} \to \mathsf{Stream} \; \mathsf{b} \\ \mathsf{map}_s \; \mathsf{f} \; (\mathsf{Stream} \; \mathsf{step} \; \mathsf{s}) &= \mathsf{Stream} \; \mathsf{step}' \; \mathsf{s} \\ &\quad \quad \mathsf{where} \\ &\quad \quad \mathsf{step}' \; \mathsf{s} = \mathbf{case} \; \mathsf{step} \; \mathsf{s} \; \mathbf{of} \\ &\quad \quad \mathsf{Yield} \; \mathsf{x} \; \mathsf{s}' \to \mathsf{Yield} \; (\mathsf{f} \; \mathsf{x}) \; \mathsf{s}' \\ &\quad \quad \mathsf{Skip} \; \mathsf{s}' \to \mathsf{Skip} \; \mathsf{s}' \\ &\quad \quad \mathsf{Done} \quad \to \mathsf{z} \end{aligned}
```

# Fusing maps

```
\mathsf{map}\; f \circ \mathsf{map}\; g \equiv \\ \mathsf{unstream} \circ \mathsf{map_s}\; f \circ \mathsf{stream} \circ \mathsf{unstream} \circ \mathsf{map_s}\; g \circ \mathsf{stream}
```

# Fusing maps

```
\mathsf{map} \ f \circ \mathsf{map} \ g \equiv \\ \mathsf{unstream} \circ \mathsf{map}_s \ f \circ \mathsf{stream} \circ \mathsf{unstream} \circ \mathsf{map}_s \ g \circ \mathsf{stream}
```

```
\begin{aligned} \mathsf{map} \ \mathsf{f} \circ \mathsf{map} \ \mathsf{g} &\equiv \\ \mathsf{unstream} \circ \mathsf{map}_{\mathsf{s}} \ \mathsf{f} \circ \mathsf{map}_{\mathsf{s}} \ \mathsf{g} \circ \mathsf{stream} \end{aligned}
```

# Fusing maps

```
\mathsf{map} \ f \circ \mathsf{map} \ g \equiv \\ \mathsf{unstream} \circ \mathsf{map_s} \ f \circ \mathsf{stream} \circ \mathsf{unstream} \circ \mathsf{map_s} \ g \circ \mathsf{stream}
```

```
\begin{aligned} \mathsf{map} \ \mathsf{f} \circ \mathsf{map} \ \mathsf{g} &\equiv \\ \mathsf{unstream} \circ \mathsf{map}_{\mathsf{s}} \ \mathsf{f} \circ \mathsf{map}_{\mathsf{s}} \ \mathsf{g} \circ \mathsf{stream} \end{aligned}
```

We get map  $f \circ map g \equiv map (f \circ g)$  for free!

# Fusing vector dot product

 $\begin{aligned} &\mathsf{dotp} :: \mathsf{Vector} \; \mathsf{Double} \to \mathsf{Vector} \; \mathsf{Double} \\ &\mathsf{dotp} \; \mathsf{v} \; \mathsf{w} = \mathsf{sum} \; (\mathsf{zipWith} \; (*) \; \mathsf{v} \; \mathsf{w}) \end{aligned}$ 

# Fusing vector dot product

 $\begin{aligned} &\mathsf{dotp} :: \mathsf{Vector} \ \mathsf{Double} \to \mathsf{Vector} \ \mathsf{Double} \to \mathsf{Double} \\ &\mathsf{dotp} \ \mathsf{v} \ \mathsf{w} = \mathsf{sum} \ (\mathsf{zipWith} \ (*) \ \mathsf{v} \ \mathsf{w}) \end{aligned}$ 

 $\begin{aligned} \text{zipWith} :: (a \to b \to c) \to \text{Vector a} \to \text{Vector b} \to \text{Vector c} \\ \text{zipWith f v w} &= \text{unstream (zipWith}_{\text{stream}} \text{ f (stream v) (stream w))} \end{aligned}$ 

 $\begin{array}{l} \operatorname{sum}::\operatorname{Num}\:\mathsf{a}\Rightarrow\operatorname{Vector}\:\mathsf{a}\to\mathsf{a}\\ \operatorname{sum}\:\mathsf{v}=\operatorname{foldl'}_{\operatorname{stream}}\:0\;(+)\;(\operatorname{stream}\:\mathsf{v}) \end{array}$ 

# Fusing vector dot product

```
\begin{split} \mathsf{dotp} &:: \mathsf{Vector\ Double} \to \mathsf{Vector\ Double} \to \mathsf{Double} \\ \mathsf{dotp} &\equiv \mathsf{sum\ } (\mathsf{zipWith\ } (*) \ \mathsf{v} \ \mathsf{w}) \\ &\equiv \mathsf{foldl'}_{\mathsf{stream\ }} 0 \ (+) \ (\mathsf{stream\ } (\mathsf{unstream\ } \mathsf{w})))) \\ &\equiv \mathsf{foldl'}_{\mathsf{stream\ }} 0 \ (+) \\ &\equiv \mathsf{foldl'}_{\mathsf{stream\ }} 0 \ (+) \\ &(\mathsf{zipWith\ }_{\mathsf{stream\ }} (+) \ (\mathsf{stream\ } \mathsf{v}) \ (\mathsf{stream\ } \mathsf{w})) \end{split}
```

# Fusing vector dot product: foldl'<sub>stream</sub>

```
\begin{array}{l} \mathsf{foldl'}_{\mathsf{stream}} :: (\mathsf{a} \to \mathsf{b} \to \mathsf{a}) \to \mathsf{a} \to \mathsf{Stream} \; \mathsf{b} \to \mathsf{a} \\ \mathsf{foldl'}_{\mathsf{stream}} \; \mathsf{f} \; \mathsf{z} \; (\mathsf{Stream} \; \mathsf{step} \; \mathsf{s}) = \mathsf{loop} \; \mathsf{z} \; \mathsf{s} \\ \quad \quad \mathsf{where} \\ \mathsf{loop} \; \mathsf{z} \; \mathsf{s} = \mathsf{z} \; \mathsf{'seq'} \\ \quad \quad \quad \mathsf{case} \; \mathsf{step} \; \mathsf{s} \; \mathsf{of} \\ \quad \quad \quad \mathsf{Yield} \; \mathsf{x} \; \mathsf{s'} \to \mathsf{loop} \; (\mathsf{f} \; \mathsf{z} \; \mathsf{x}) \; \mathsf{s'} \\ \quad \quad \quad \mathsf{Skip} \; \mathsf{s'} \to \mathsf{loop} \; \mathsf{z} \; \mathsf{s'} \\ \quad \quad \mathsf{Done} \quad \quad \to \mathsf{z} \end{array}
```

# Fusing vector dot product: zipWith<sub>stream</sub>

```
zipWith_{stream} :: (a \rightarrow b \rightarrow c) \rightarrow Stream \ a \rightarrow Stream \ b \rightarrow Stream \ c
zipWith<sub>stream</sub> f (Stream stepa sa na) (Stream stepb sb nb) =
      Stream step (sa, sb, Nothing) (min na nb)
   where
      step (sa, sb, Nothing) =
         case stepa sa of
            Yield x sa' \rightarrow Skip (sa', sb, Just x)
            Skip sa' \rightarrow Skip (sa', sb, Nothing)
            Done \rightarrow Done
      step (sa, sb, Just x) =
         case stepb sb of
            Yield y sb' \rightarrow Yield (f x y) (sa, sb', Nothing)
            Skip sb' \rightarrow Skip (sa, sb', Just x)
            Done \rightarrow Done
```

dotp after inlining etc.

```
\begin{aligned} &\mathsf{dotp}\;(\mathsf{Vector}\;\mathsf{n}\;\mathsf{u})\;(\mathsf{Vector}\;\mathsf{m}\;\mathsf{v}) = \mathsf{loop}\;0.0\;0\;0\\ &\mathsf{where}\\ &\mathsf{loop}\;\mathsf{z}\;\mathsf{i}\;\mathsf{j}\\ &\mathsf{\mid}\;\mathsf{i}<\mathsf{n}\;\wedge\;\mathsf{j}<\mathsf{m}=\mathsf{loop}\;(\mathsf{z}+\mathsf{u}\;!!\;\mathsf{i}\;*\;\mathsf{v}\;!!\;\mathsf{j})\;(\mathsf{i}+1)\;(\mathsf{j}+1)\\ &\mathsf{\mid}\;\mathsf{otherwise} &=\mathsf{z} \end{aligned}
```

# dotp inner loop

#### Stream fusion limitations

#### data Stream a where

 $\mathsf{Stream} :: (\mathsf{s} \to \mathsf{Step} \; \mathsf{s} \; \mathsf{a}) \to \mathsf{s} \to \mathsf{Int} \to \mathsf{Stream} \; \mathsf{a}$ 

- ▶ How to support SSE instructions in this framework?
- Efficient implementations of append, replicate?

▶ No single "best" stream representation.

- ▶ No single "best" stream representation.
- ► Bundle multiple stream representations together.

```
data Bundle a = Bundle
  { sSize :: Size
  , sElems :: Stream a
  , sChunks :: Stream (Chunk a)
  , sMultis :: Multis a
  }
```

- ▶ No single "best" stream representation.
- ▶ Bundle multiple stream representations together.
- ► Stream consumer chooses most advantageous representation.

- ▶ No single "best" stream representation.
- ▶ Bundle multiple stream representations together.
- Stream consumer chooses most advantageous representation.
- Identical semantics, different cost models.

# Using SSE instructions in GHC

- Add support for SSE primitives to code generator(s).
- ► Add boxed SSE types: associated type Multi a.
- ► Fix the register allocator.
- High-level interface—via generalized streams and the vector library.

$$\label{eq:data_entropy} \begin{split} & \textbf{data} \; \text{Either a b} = \text{Left a} \; | \; \text{Right b} \\ & \textbf{type} \; \text{Multis a} = \text{Stream} \; (\text{Either a} \; (\text{Multi a})) \end{split}$$

```
\begin{tabular}{ll} \beg
```

▶ Stream consumer has to take what it can get.

```
\begin{tabular}{ll} \beg
```

- Stream consumer has to take what it can get.
- ► Fine for map or fold...

```
data Either a b = Left a | Right b
type Multis a = Stream (Either a (Multi a))
\mathsf{msum}_{\mathsf{s}} :: (\mathsf{Num} \ \mathsf{a}, \mathsf{Num} \ (\mathsf{Multi} \ \mathsf{a})) \Rightarrow \mathsf{Multis} \ \mathsf{a} \to \mathsf{a}
msum_s (Stream step s _) = loop 0.0 \ 0.0 \ s
  where
      loop summ sum1 s =
         case step s of
           Yield (Left x) s' \rightarrow loop summ (sum1 + x) s'
            Yield (Right y) s' \rightarrow loop (summ + y) sum1
            Skip s' \rightarrow loop summ sum1
                                  \rightarrow multifold (+) sum1 summ
            Done
```

$$\label{eq:data_entropy} \begin{split} & \textbf{data} \; \text{Either a b} = \text{Left a} \; | \; \text{Right b} \\ & \textbf{type} \; \text{Multis a} = \text{Stream} \; (\text{Either a} \; (\text{Multi a})) \end{split}$$

What about zipWith?

#### data Multis a where

- ▶ Stream consumer gets to choose what it gets.
- ► Works for zipWith, map, fold...
- What happens when appending two streams?

#### data MultiStream a where

$$\begin{aligned} \mathsf{MultiStream} \; & :: \; (\mathsf{s} \to \mathsf{Step} \; \mathsf{s} \; (\mathsf{Multi} \; \mathsf{a})) \\ & \to (\mathsf{s} \to \mathsf{Step} \; \mathsf{s} \; \mathsf{a}) \\ & \to \mathsf{s} \\ & \to \mathsf{MultiStream} \; \mathsf{a} \end{aligned}$$

But stream operations may "mix" scalars and Multi's, e.g., append.

#### data MultiStream a where

```
\label{eq:multiStream} \begin{array}{l} \mathsf{MultiStream} \ :: \ (\mathsf{s} \to \mathsf{Step} \ \mathsf{s} \ (\mathsf{Multi} \ \mathsf{a})) \\ \to \ (\mathsf{s} \to \mathsf{Step} \ \mathsf{s} \ \mathsf{a}) \\ \to \ \mathsf{s} \\ \to \ \mathsf{MultiStream} \ \mathsf{a} \end{array}
```

- But stream operations may "mix" scalars and Multi's, e.g., append.
- Some operations, like fold, are agnostic to "mixing." Others, like zipWith, are not.

#### data MultiStream a where

```
\begin{aligned} \mathsf{MultiStream} \; & :: \; (\mathsf{s} \to \mathsf{Step} \; \mathsf{s} \; (\mathsf{Multi} \; \mathsf{a})) \\ & \to (\mathsf{s} \to \mathsf{Step} \; \mathsf{s} \; \mathsf{a}) \\ & \to \mathsf{s} \\ & \to \mathsf{MultiStream} \; \mathsf{a} \end{aligned}
```

- ▶ But stream operations may "mix" scalars and Multi's, e.g., append.
- Some operations, like fold, are agnostic to "mixing." Others, like zipWith, are not.

```
\label{eq:type_multis} \textbf{type} \; \mathsf{MultiStream} \; \mathsf{m} \; \mathsf{a}) \\ (\mathsf{Stream} \; \mathsf{m} \; (\mathsf{Either} \; \mathsf{a} \; (\mathsf{Multi} \; \mathsf{a})))
```

```
A more difficult challenge
   double ddotp(double* u, double* v, int n)
   {
      union d2v d2s = \{0.0, 0.0\};
      double s;
      int i;
      for (i = 0; i < m; i += VECTOR_SIZE)</pre>
          d2s.v += (*((v2sd*)
             (u+i))*(*((v2sd*)(v+i)));
      s = d2s.d[0] + d2s.d[1];
      for (; i < n; ++i)</pre>
          s += u[i] * v[i]:
      return s:
```

### SIMD dot product in Haskell

 $\begin{aligned} &\mathsf{dotp} :: \mathsf{Vector} \; \mathsf{Double} \to \mathsf{Vector} \; \mathsf{Double} \\ &\mathsf{dotp} \; \mathsf{v} \; \mathsf{w} = \mathsf{msum} \; (\mathsf{mzipWith} \; (*) \; \mathsf{v} \; \mathsf{w}) \end{aligned}$ 


## SIMD dot product in Haskell

```
\begin{aligned} &\mathsf{dotp} :: \mathsf{Vector} \; \mathsf{Double} \to \mathsf{Vector} \; \mathsf{Double} \\ &\mathsf{dotp} \; \mathsf{v} \; \mathsf{w} = \mathsf{msum} \; (\mathsf{mzipWith} \; (*) \; \mathsf{v} \; \mathsf{w}) \end{aligned}
```


$$\begin{array}{l} \mathsf{mfold'} \ :: \ (\mathsf{Num} \ \mathsf{a}, \mathsf{Num} \ (\mathsf{Multi} \ \mathsf{a})) \\ \Rightarrow (\forall \mathsf{b}. \mathsf{Num} \ \mathsf{b} \Rightarrow \mathsf{b} \to \mathsf{b} \to \mathsf{b}) \\ \to \mathsf{a} \to \mathsf{Vector} \ \mathsf{a} \to \mathsf{a} \end{array}$$

 $\label{eq:msum::(Num a, Num (Multi a)) <math>\Rightarrow$  Vector a  $\rightarrow$  a msum = mfold' (+) 0


# dotp performance



# dotp performance: Haskell beats C



# dotp performance: Haskell beats C



### Haskell inner loop


 $\begin{aligned} &\mathsf{dotp} :: \mathsf{Vector} \; \mathsf{Double} \to \mathsf{Vector} \; \mathsf{Double} \\ &\mathsf{dotp} \; \mathsf{v} \; \mathsf{w} = \mathsf{msum} \; (\mathsf{mzipWith} \; (*) \; \mathsf{v} \; \mathsf{w}) \end{aligned}$ 

# Haskell inner loop

```
\begin{aligned} &\mathsf{dotp} :: \mathsf{Vector} \ \mathsf{Double} \to \mathsf{Vector} \ \mathsf{Double} \\ &\mathsf{dotp} \ \mathsf{v} \ \mathsf{w} = \mathsf{msum} \ (\mathsf{mzipWith} \ (*) \ \mathsf{v} \ \mathsf{w}) \end{aligned}
```

```
.LBB5 5:
   prefetcht0 (%rdx)
   movupd -1408(\%rdx), \%xmm2
   prefetcht0 (%rsi)
   movupd -1408(%rsi), %xmm1
   mulpd %xmm2, %xmm1
   addpd
            %xmm1, %xmm0
   addq $16, %rdx
   addq $16, %rsi
   addq $2, %rax
            %rcx, %rax
   cmpq
   jl
             .LBB5_5
```

### Parallelization for free



# Abstraction without cost: radial basis function


$$K(\vec{x}, \vec{y}) = e^{-\nu \|\vec{x} - \vec{y}\|^2}$$

### Abstraction without cost: radial basis function

$$K(\vec{x}, \vec{y}) = e^{-\nu ||\vec{x} - \vec{y}||^2}$$

```
\label{eq:rbf:couble} \begin{split} \text{rbf:: Double} & \to \text{Vector Double} \to \text{Vector Double} \to \text{Double} \\ \text{rbf } \nu \text{ v w} &= \text{exp } \left( -\nu * \text{msum } \left( \text{mzipWith norm v w} \right) \right) \\ \textbf{where} \\ \text{norm } \mathbf{x} \text{ y} &= \text{square } \left( \mathbf{x} - \mathbf{y} \right) \\ \text{square } \mathbf{x} &= \mathbf{x} * \mathbf{x} \end{split}
```

# rbf performance



#### Generalized Stream Fusion Conclusions

- ► Key idea: simultaneously maintain multiple representations with different cost models.
- ► Can make use of bulk memory operations like memcpy and memset (in draft paper).
- Allows us to take advantage of SSE instructions from high-level code.
- Use of SSE instructions in DPH requires no code modifications.
- Not limited to Haskell.